

01-generative-grammars

01-generative-grammars

Componenti in modo informale

- **Vocabolario:** un insieme di simboli.
 - Alcuni dei quali chiamati *terminali* costituiscono i token di output dell'*analisi lessicale*.
E.g. dato il vocabolario $\{S, a, b\}$ allora a e b sono i non terminali.
 - Viene scelto un simbolo non terminale dal vocabolario come *start symbol*.
E.g. preso il vocabolario precedente S è lo *start symbol*.
- **Produzioni:** un insieme di regole per di stringhe in altre stringhe.
Dobbiamo rispettare delle regole, per esempio la stringa da rimpiazzare deve contenere almeno un non terminale.
E. g. $\{S \rightarrow aSb, S \rightarrow ab\}$

Linguaggio

E' un insieme di parole composte da non terminali che possono essere generate partendo dallo *start symbol* applicando x volte e in y modi diversi le regole di derivazione.
Ogni riscrittura viene detta *derivation step*.

Esempio

Data la grammatica $\{S \rightarrow aSb, S \rightarrow ab\}$ possiamo compiere un paio di passi di derivazione.
 $S \Rightarrow aSb \Rightarrow aabb$; con due passi abbiamo ottenuto una parole che appartiene al linguaggio.
 $S \Rightarrow aSb \Rightarrow aaSbb \Rightarrow aaabbb$; con tre passi abbiamo ottenuto una parola valida.
Possiamo concludere che il linguaggio generato dalla grammatica ha la forma $\{a^n b^n \mid n > 0\}$,

Convenzioni sulla ε

Usiamo il carattere speciale ε per denotare la parola vuota, ha le seguenti proprietà:

- $\varepsilon \equiv \varepsilon\varepsilon$
- $\varepsilon \equiv b^n$ per ogni terminale b

Esempio

$S \rightarrow aAb$

$aA \rightarrow aaAb$

$$A \rightarrow \varepsilon$$

Il linguaggio generato è $\{a^n b^n \mid n > 0\}$, quindi grammatiche diverse possono generare linguaggi uguali.

Esempio

$$S \rightarrow AB$$

$$A \rightarrow aA$$

$$A \rightarrow a$$

$$B \rightarrow Bb$$

$$B \rightarrow b$$

$$S \implies AB \implies aAB \implies aaB \implies aab$$

Genera il linguaggio $\{a^n b^m \mid n, m > 0\}$

Esempio

$$S \rightarrow AB$$

$$A \rightarrow a$$

$$S \implies AB \implies aB$$

Quindi non arrivo mai ad una parola priva di non terminali per cui il linguaggio generato è \emptyset

Esempio

$$S \rightarrow \varepsilon$$

Viene generato il linguaggio $\{\varepsilon\}$ che è $\neq \emptyset$

Esempio

$$S \rightarrow aSb$$

$$S \rightarrow \varepsilon$$

Genera il linguaggio $\{a^n b^n \mid n > 0\} \cup \{\varepsilon\} = \{a^n b^n \mid n \geq 0\}$

Componenti in modo formale

Una grammatica è una tupla (V, T, S, P)

- **V**: vocabolario con terminali e non.
- **T**: insieme dei terminali.
- **S**: simbolo di inizio che si trova in $(V \setminus T)$.
- **P**: insieme delle produzioni.

Notazione

- Maiuscole iniziali dell'alfabeto: $A, B, \dots \in (V \setminus T)$
- Maiuscole finali dell'alfabeto: $X, Y, \dots \in V$
- Minuscole iniziali dell'alfabeto: $a, b, \dots \in T$
- Minuscole iniziali dell'alfabeto greco: $\alpha, \beta, \dots \in V^*$
'*' sta ad indicare che ci possono essere più ripetizioni degli elementi nell'insieme di partenza
- Stringhe di terminali: w, w_0, \dots
- **Produzioni:** $\delta \rightarrow \beta$
 - $\delta \in V^+$, ovvero tutti i simboli del vocabolario esclusa ε
 - δ contiene almeno un non terminale
 - δ è chiamato **driver** della produzione
 - β è chiamato **body** della produzione
- **Linguaggio generato:** $L(G) = \{w | w \in T^* \text{ and } S \Rightarrow w\}$
Usiamo T^* perchè la parola w potrebbe essere solo ε

Gerarchia delle grammatiche

Dipendono dalla forma delle produzioni.

Passiamo ora a vedere alcuni tipi di grammatiche.

Grammatiche context-free

Le grammatiche *context-free* o *free* hanno solo produzioni della forma:

$$A \rightarrow \beta$$

Linguaggi context-free

L è un linguaggio *context-free* se e solo se esiste una grammatica *context-free* tale che:

$$L = L(G)$$

Derivazioni

- **Rightmost/Leftmost:** rimpiazziamo il non terminale più a destra/sinistra indipendentemente dalle scelte precedenti.
- **Canoniche:** se inizio con derivazioni rightmost continuo con esse e viceversa per leftmost.

Alberi di derivazione

I linguaggi liberi possono essere rappresentati come un albero tale che:

- Lo *start symbol* è la radice.
- Per ogni passo di derivazione si aggiunge un livello.

- La produzione $A \rightarrow X_1X_2 \dots X_n$ genera i nodi figli $X_1X_2 \dots X_n$ che partono dal nodo A .
- Le foglie sono i caratteri terminali, compresa ε .
- La parola generata è la concatenazione delle foglie dell'albero.


Ambiguità

Una grammatica G è ambigua se e solo se esiste una parola $w \in L(G)$ che può essere generata da due derivazioni canoniche distinte, anche entrambe rightmost o leftmost.

Esempio

$E \rightarrow E+E \mid E^*E \mid n$; è ambigua?

Prendiamo $w=n+n*n$



Come si può vedere anche se abbiamo cambiato derivazioni canoniche la parola generata è la stessa.

Osservazioni

L'ambiguità è indecidibile e non possono essere creati algoritmi in grado di capire se una grammatica è ambigua o meno.