# 09-intermidiate-code-generator

Ripercorriamo un istante tutte le fasi di front-end che abbiamo visto fino ad ora:

- Analisi lessicale: riconosce i vari lessemi e restituisce una stringa i token ovvero quegli elementi di cui ha bisogno l'analizzatore sintattico.
- Anlisi sintattica: tutto il parsing, quindi verifica se una serie di token appartiene o meno al linguaggio di nostra comeptenza.
- Analisi semantica: compie controlli statici sulla compatibilità tra operatori e operandi come la validità delle istruzioni di controllo e condizionali come if e while.
- Generazione di codice intermedio: che vedremmo ora
   E' possibile implementare l'analisi semantica durante l'analisi sintattica, ma questa agglomerazione è possibile anche con la generazione di codice intermedio che può essere fatta durante il parsing.

## **Codice intermedio**

E' il passo intermedio tra il nostro codice ed il codice macchina, rende più leggibile il codice macchina avvicinandosi molto.

E.g. nasconde le specifiche come il movimento di valori tra registri e memoria.

## Rappresentazione intermedia

Abbiamo più di una possibilità per poter vedere il codice intermedio, ma 3 sono le maggiori:

- 1. **Struttura a grafo**: partendo dai *parse tree* possiamo avere delle strutture a grafi come gli *AST* oppure un grafo diretto aciclico *DAG*, solitamente i *DAG* risultano più succinti degli *AST*.
- 2. Codice a 3 indirizzi: impedisce direferenziare più di tre avlori per ogni singolo statement riduce di molto la complessità degli statement stessi, genera codice della forma x = y op z.

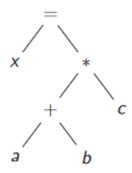
Noi useremo questa alternativa.

3. **Altro linguaggio:** utilizzare un altro linguaggio di programmazione, questo approccio ci salva dal dover implemenatre da 0 un back-end per il compilatore.

La scelta preferita da molti è c per il suo compilatore estremamente efficente.

#### Codice a 3 indirzzi

E' la rappresentazione testuale di un *AST*, come al solito un esempio vale più di mille parole. Prendiamo l'*abstract syntax tree* che rappresenta una semplice espressione aritmetica.



L'espressione risulta essere x = a + b \* c, con precedenza all'addizione.

Come possiamo però vedere stiamo usndo 4 riferimenti nello statement, dobbiamo quindi spezzarli:

```
t1 = a + b
t2 = t1 * c
x = t2
```

Abbiamo a disposizione una grande varietà di istruzioni:

```
• a1 = a2 \text{ op } a3
```

• a1 = op a2

• a1 = a2

a1 = a2[a3]

a1[a2] = a3

goto L

• if a goto L

• ......

Però la rappresentazione in modo testuale a 3 indirzzi ci facilita molto la generazione e l'ottimizzazione del codice macchina, tuttavia non è una tecnica così utilizzata perchè è troppo *machine dependent*.

#### Codice intermedio

Supponiamo di avere un espressione del tipo:

```
if ( x < 100 || x > 200 && x != y ) x=0;
```

Una sua prima trasformazione in codice intermedio potrebbe essere:

```
IF x < 100 GOTO L2

GOTO L3

L3: IF x > 200 GOTO L4

GOTO L1

L4: IF x != y GOTO L2
```

```
GOTO L1
L2: x = 0
L1:
```

Però questo codice può essere ottimizzato, ovvero possiamo notare che controllando la falsità di alcuni statement possiamo eliminare dei GOTO ridondanti.

```
IF x < 100 GOTO L2
    IF x <= 200 GOTO L1
    IF x == y GOTO L1
L2: x = 0
L1:</pre>
```

#### Traduzione guidata da sinstassi

Possiamo quindi tradurre un *AST* in una serie di istruzioni a 3 operatori, come? Prendiamo in esame la seguente grammatica:

$$egin{cases} S 
ightarrow id = E \ E 
ightarrow E_1 + E_2 \ E 
ightarrow - E_1 \ E 
ightarrow (E_1) \ E 
ightarrow id \end{cases}$$

l'obbiettivo è di produrre del codice a 3 indirizzi con l'utilizzo di attributi e funzioni ausiliri:

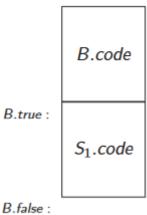
- E.addr l'indirzzo di memoria in cui c'è il valore di E
- S.code e E.code indicano il codice emesso da S e E
- gen(str) emette la stringa str
- newtemp() genera un nuovo nodo
- questo simbolo indica la concatenazione tra frammenti di codice intermedio Quindi possiamo arricchire la grammatica che sta sopra con:

#### Statement di controllo di flusso

Prendiamo una possibile grammatica come :

```
S 	o if(B) \ S_1
S 
ightarrow if(B) \ S_1 \ else \ S_2
S 	o while(B) \ S_1
```

Il nostro cruccio è capire come vengono tradotti quei salti dati dalle istruzioni condizionate. Osservando un blocco if-then ci accorgiamo che la sua struttura potrebbe essere:



Dove l'etichetta B. true punta alla prima istruzione a eseguire se la condizione è vera mentre B.false punta alla prima istruzione dopo la chiusura del blocco then. Per poter implementare questi salti ci servono degli attributi per poter fare dei salti, ovviamente questi attributi possono essere sia ereditati che sintetizzati:

- S.next, ereditato, indica la prima istruzione da eseguire terminato il blocco di codice S.
- S.code, sintetizzato, è la sequenza di codice intermedio che implemeneta lo stato S e termina con un salto a S.next.
- B.true, ereditato, indica l'inizio del codice che va eseguito se B è true.
- B.false, ereditato, indica l'inizio del codice da eseguire se B è false.
- B.code, ereditato, è la sequenza i codice intermedio che implementano la condizione B e fanno il salto alle label B.true oppure B.false.

N.B: i booleani possono avere due ruoli diversi:

- 1. Alterare il flusso del programma con condizioni booleane.
- 2. Calcolare il valore di espressioni logiche.

Noi consideriamo solo il loro primo utilizzo, ovvero quello per il controllo di flusso, perchè per il loro secondo ruolo i booleani si comportano esattamente come operatori aritmetici (con le loro regole ecc...).

Spesso le grammatiche hanno non-terminali diversi per distinguere i booleani nelle condizioni e nelle espressioni logiche.

#### Esempio

Andiamo a prendere la prima produzione della nostra grammatica, ovvero  $P \to S$  la sitassi del suo codice intermedio sarà più o meno:

```
P 
ightarrow S \qquad \{S.\,next = newlabel(); \;\; P.\,code = S.\,code 
ightarrow label(S.\,next)\}
```

Quindi il nostro programma P può essere visto come un enorme statement S. Vediamo quindi le nuove funzioni usate:

- newlabel(): una volta invocata genera una nuova etichetta.
- label(L): assegna l'etichetta L alla prossima istruzione a 3 indirizzi generata. Solitamente nei frammenti dove si fa uso dei salti condizionati diventa imperatico l'uso del comando GOTO per saltare ad una determinata label.

Quindi adesso vediamo come verrebbe arricchita quella grammatica dalle istruzioni di generazione di codice intermedio.

```
P -> S S.next = newlabel()
                P.code = S.code ▷ label(S.next)
S -> if(B) S1 B.true = newlabel()
                                B.false = S.next
                                S1.next = S.next
                                S.code = B.code ▷ label(B.true) ▷ S1.code
S -> if(B) S1 else S2 B.false = newlabel()
                                                 B.true = newlabel()
                                                 S1.next = S.next
                                                 S2.next = S.next
                                                 S.code = B.code ▷ lable(B.true)
\triangleright
                                                         S1.code ⊳ gen(GOTO
S.next) ⊳
                                                         label(B.false) ⊳ S2.code
S -> while(B) S1 B.true = newlabel()
                                         B.false = S.next
                                         S1.next = newlabel()
                                         S.code = label(S1.next) ▷ B.code ▷
                                                 label(B.true) ▷ S1.code ▷
                                                 gen(GOTO S1.next)
B -> true B.code = gen(GOTO B.true)
B -> false B.code = gen(GOTO B.false)
B -> not B1 B1.true = B.false
                                B1.false = B.true
                                B.code = B1.code
B -> E1 rel E2 B.code = E1.code ▷ E2.code ▷
```

Procediamo all'analisi blocco per blocco.

## Blocco if-then

Per prima cosa creiamo un'etichetta alla quale puntare se B risultui vero, invece se B dovesse risultare falsa possiamo saltare per intero lo statement S1 e quindi per via dell'assenza di un else saltare subito a S.next.

Quindi nel complesso il valore da dare al nostro statement S è composto da il codice per interpretare B, la label alla quale saltare se B è vero ed infine il codice situato in questa label.

#### Blocco if-the-else

Eleviamo ora il caso precedente al caso in cui ci sia anche un blocco else.

Creiamo le due label in caso B sia o vero o falso e puntiamo il successivo dei due microstatement al successivo dello statement nel driver della produzione.

Ora assembliamo tutto e otteniamo il codice di calcolo di B se è vero saltiamo al codice di S1 per poi fare un GOTO S.next se invece è falso facciamo un salto a S2.code ed eseguiamo il codice.

#### Ciclo while

Potremmo vederlo come un blocco if-then che si ripete più volte, infatti per B.true generiamo una nuova label, mentre per B.false andiamo al prossimo statement. Il successivo dello statement interno viene identificato a una nuova label che punterà poi all'inizio del ciclo.

Nel comlpessivo il codice di S è la creazione della label per S1.next, il codice per computare B, se è vera eseguo S1.code e salto a S1.next quindi riparto dall'inizio e rifaccio il controllo su B, se è true ripeto il ciclo altrimenti vado a S.next.

#### Operazioni booleane

Occhio, qui si compie **SMART EVALUATION** non lazy come molti lazzaroni dicono, se all'orale dite lazy penso che la Quaglia vi fulmini.

Partiamo con l'OR, basta che il primo elemento sia vero, quindi se B1 è vero punteremo a B.next mentre se è falso ad una nuova label, per quanto riguarda B2 se è vero punteremo a B.true mentre se è falso a B.false, questo perchè è l'ultima espressione da analizzare e il suo valore determinerà quello dell'espressione.

Quindi il codice dell'espressione sarà il codice per calcolare B1 seguito dalla label se B1 è false e quindi dal codice per computare B2.

Bene, ora per l'AND vale tutto quello appena detto ma semi-specchiato perchè devono essere veri entrambi gli elementi.

## Evitare GOTO ridondanti

Dobbiamo ipotizzare che se la condizione booleana risulta vera dobbiamo eseguire l'istruzione prossima in sequenza (quindi nella riga sottostante).

Creiamo quindi una nuova keyword per indicare di non fare un GOTO ad una label specifica bensì di eseguire l'istruzione successiva, questa keyword sarà fall.

Facciamo un po' di esempi con la grammatica precedente.

```
P -> S S.next = newlabel()

P.code = S.code ▷ lable(S.next)

S -> if(B) S1 B.true = fall

B.false = S.next

S1.next = S.next

S.code = B.code ▷ S1.code

S -> while(B) S1 B.true = fall

B.false = s.next

S1.next = newlabel()

S.code = label(S1.next) ▷ B.code ▷

S1.code ▷ gen(GOTO S1.next)

B -> true if B.true != fall then gen(GOTO B.true)

B -> false gen(GOTO B.false)

ecc.....
```

#### Non fare 2 passate: Backpatching

Prendiamo in esame la seguente produzione

```
S -> if(B) S1 B.true = fall

B.false = S.next

S1.next = S.next

S.code = B.code ▷ S1.code
```

Quando il codice per **B** è generato non conosciamo ancora **S.next** quindi sarebbero necessarie due passate, una per generare il codice ed un'altra per poter inserire le destinazioni dei salti.

Per fortuna la Prof. ci ha svelato una strategia che ci farà dire "abbiamo vinto". Per poter applicare la strategia del *backpatching* dobbiamo assumere che le istruzioni siano generate in un array e le label indichino degli indici per accedere all'array. Consideriamo i seguenti attributi:

- B.truelist attributo sintetizzato in cui c'è la lista dei salti in cui dobbiamo inserire una label se B risulta true.
- B.falselist attributo sintetizzato in cui c'è la lista dei salti in cui dobbiamo inserire una label se B risulta false.
- nextinstruction contiene l'indice dell'istruzione successiva.
- makelist(i) crea una lista contenente l'indice i, restituisce il puntatore a quella lista.
- merge(p1, p2) concatena le liste p1 e p2, restituisce il puntatore alla lista creata.
- backpatch(p, i) inserisce la label i in tutti i salti incompleti contenuti nella lista p. Generiamo salti incompleti quindi della forma GOTO μ, per esempio:

Dove il nuovo non-terminale M serve a puntare alla prossima istruzione.

```
M -> ε M.instr = nextinstr
```

### Esempio

Prendiamo in esame la nostra grammatica delle espressioni booleane.

## Indirizzamento degli elementi di un array

Il più grande problema con la gestione dei vettori mono/bi dimensionali (vedremo solo questi per semplicità) è il calcolo degli indirizzi dei loro elementi, dobbiamo tenere a mente che sono aree di memoria contigue.

Esistono due strategie principali per la memorizzazione degli array:

- Row-major: il modo più diffuso nonchè quello che utilizzeremo noi, consiste nel far variare il secondo indice (nel caso di una matrice) perchè viene memorizzato tutto dando precedenza alle righe, infatti in una matriche M di dimensioni  $2 \times 4$  gli elemnti sono nel seguiente ordine ordine M[0][0], M[0][1], M[0][2], M[0][3], M[1][0], M[1][1], M[1][2] e M[1][3].
- Colum-major: cambia l'indice più a sinistra e si percorre colonna per colonna, quindi in una matriche M di dimensioni  $2\times 4$  gli elemnti sono nel seguiente ordine ordine  $M[0][0], M[1][0], M[0][1], M[1][1], M[0][2], M[1][2], \ldots$  Se gli elementi immagazzinati in un array **monodimensionale** sono  $0,1,\ldots,n$  allora possiamo facilmente calcolare l'indirro dell'i-esimo elemento, basta sapere l'indirzzo del

primo elemento detto base e la lunghezza di ogni elemento detta w:

$$address\ of\ M[i] = base + (i*w)$$

Se invece parliamo di un array **bidimensionali** dobbiamo anche conoscere la lunghezza di un'intera riga  $w_1$  allora l'indirizzo è calcolabile come:

$$address\ of\ M[i][j] = base + (i*w_1) + (j*w)$$

#### Traduzione syntax-directed di un array

Prendiamo una grammatica che generi vettori a n dimensioni

$$\left\{egin{aligned} S 
ightarrow id = E \mid L = E \ E 
ightarrow E + E \mid id \mid L \ L 
ightarrow id[E] \mid L[E] \end{aligned}
ight.$$

#### Dobbiamo usare i seguenti attributi:

- L.addr indica una variabile temporanea per computare l'offset.
- L.array è il riferimento alla entry nella tabella dei simboli che contiene il nome dell'array, la entry contiene anche varie info:
  - L'indirzzo base dell'array L.array\_base
  - La larghezza di ogni elemento L-array\_ewidth
- L.width la larghezza del sotto-array generato da
   Vediamo ora produzione per produzione